BILAGA D: PRESENTERA OCH ANALYSERA DATA

Analys av vattenkvalitet och vattentekniska processer bygger på mätningar. Innan mätdata kan användas för att dra slutsatser måste man förstå hur de har samlats in och vilka osäkerheter som finns. Frågor som mätinstrumentens upplösning, precision, noggrannhet och hur många värdesiffror som är rimliga att rapportera påverkar hur resultaten ska tolkas.

Mätdata behöver också granskas innan analyser genomförs. Extremvärden kan bero på mätfel, felaktig datainmatning eller verkliga händelser i systemet. Därför är det viktigt att undersöka kvalitet och variation hos data innan man beräknar medelvärden eller genomför statistiska analyser.

I denna bilaga beskrivs grundläggande metoder för att presentera, granska och analysera vattenkvalitetsdata. Exempel ges på hur data kan sammanfattas i tabeller och diagram, hur extremvärden kan identifieras samt hur resultat kan analyseras med hjälp av enkla statistiska metoder. I det här kapitlet finns det också rutor med kod som visar hur data kan analyseras och presenteras med Python. Vi använder *Pandas*, ett Python-paket för datahantering och analys, *Numpy* for numeriska beräkningar, *Matplotlib* för att skapa diagram och visualiseringar, samt *SciPy* och *Statsmodels* som bland annat innehåller verktyg för statistiska analyser. Filer med exempeldata kan laddas ner från omvatten.github.io/textbook.

Upplösning, precision och noggrannhet

Alla mätningar innehåller osäkerheter. För att kunna tolka mätdata korrekt är det viktigt att förstå skillnaden mellan upplösning, precision och noggrannhet.

Upplösning beskriver den minsta förändring som ett instrument kan visa. Om en konduktivitetsmätare visar värden med tre decimaler, exempelvis 1,413 mS/cm, är instrumentets upplösning 0,001 mS/cm. En hög upplösning betyder dock inte automatiskt att mätningen är exakt eller tillförlitlig.

Precision beskriver hur lika upprepade mätningar av samma prov blir. Om ett vattenprov analyseras flera gånger och resultaten ligger mycket nära varandra har mätningen hög precision. Precision handlar alltså om hur liten spridningen är mellan upprepade mätningar.

Noggrannhet beskriver hur nära det uppmätta värdet ligger det sanna värdet. Ett instrument kan ge mycket liknande resultat vid upprepade mätningar och därmed ha hög precision, men ändå systematiskt visa för höga eller för låga värden. I så fall är noggrannheten låg.

Antag att samma vattenprov analyseras tio gånger med resultatet som visas i Tabell 1. Medelvärdet av mätningarna är 1,411 mS/cm och standardavvikelsen är 0,016 mS/cm. Variationen mellan mätningarna ger information om metodens precision. Däremot går det inte att avgöra noggrannheten utan att jämföra med ett referensprov vars verkliga konduktivitet är känd.

När mätdata rapporteras bör antalet siffror anpassas till mätningens kvalitet. Om osäkerheten är betydligt större än instrumentets upplösning saknar extra decimaler praktisk betydelse. Att rapportera medelvärdet från mätningarna i Tabell 1 som 1,411 mS/cm ger därför en missvisande bild av mätningens precision i det här exemplet.

Tabell 1. Upprepade mätningar av konduktivitet i ett vattenprov.

Mätning	Konduktivitet (mS/cm)
1	1,389
2	1,421
3	1,397
4	1,438
5	1,406
6	1,415
7	1,394
8	1,427
9	1,401
10	1,418

Exempel i Python: Få grundläggande information om datatabeller.

```
import pandas as pd
df = pd.read_csv("BilagaD_konduktivitet.csv")
print(df.describe())
```

Värdesiffror och rapportering av mätdata

När mätresultat rapporteras bör antalet siffror spegla den information som faktiskt finns i mätningen. Att ange fler siffror än vad mätningens precision motiverar ger ett falskt intryck av säkerhet, medan för få siffror kan göra att viktig information går förlorad.

Låt oss titta på konduktivitetsmätningarna i Tabell 1. De tio upprepade mätningarna gav ett medelvärde på 1,411 mS/cm och en standardavvikelse på 0,016 mS/cm. Standardavvikelsen är betydligt större än instrumentets upplösning på 0,001 mS/cm. Variationen mellan mätningarna sker alltså främst på den andra decimalen. Det vore därför olämpligt att rapportera resultatet som 1,411 mS/cm eftersom den sista siffran ger ett intryck av en precision som inte stöds av mätdata. Ett rimligare sätt att rapportera resultatet är 1,41 mS/cm eller 1,41 ± 0,02 mS/cm (medelvärde ± standardavvikelse) där osäkerheten anges med standardavvikelsen avrundad till samma antal decimaler som medelvärdet.

Antalet värdesiffror bör också anpassas efter hur resultatet har tagits fram. Om ett värde beräknas genom multiplikation eller division bör svaret normalt inte innehålla fler värdesiffror än det ingående mätvärde som har lägst antal värdesiffror. Om ett värde istället beräknas genom addition eller subtraktion bör antalet decimaler i svaret motsvara det ingående värdet med lägst antal decimaler.

När data presenteras måste såklart även enheter anges. En tabell eller figur utan enheter är i praktiken värdelös eftersom det inte går att tolka de numeriska värdena. Enheterna bör därför anges antingen tillsammans med parameterns namn eller i figurens axelrubriker.

Identifiering av extremvärden

Innan mätdata analyseras bör man undersöka om datamängden innehåller extremvärden. Ett extremvärde är ett mätvärde som skiljer sig tydligt från övriga observationer. Extremvärden kan uppstå på grund av mätfel, felaktig datainmatning eller ovanliga händelser i det system som undersöks. I vattenkvalitetsdata kan extremvärden exempelvis orsakas av kraftig nederbörd, bräddningar, instrumentfel eller problem vid laboratorieanalysen. Ett extremvärde ska därför inte automatiskt tas bort från datamängden. Först bör man undersöka om det finns en rimlig förklaring till

observationen.

IQR-metoden. En vanlig metod för att identifiera extremvärden är IQR-metoden (Interquartile Range). Först bestäms första kvartilen (Q1) och tredje kvartilen (Q3) i datasetet. Avståndet mellan dessa värden kallas interkvartilsavståndet (IQR).

$$IQR = Q_3 - Q_1$$

Därefter beräknas följande nedre och övre gränser. Observationer som ligger utanför dessa gränser betraktas som extremvärden.

$$Nedre\ gräns = Q_1 - 1{,}5 \times IQR$$

$$Övre\ gräns = Q_3 + 1{,}5 \times IQR$$

Exempel i Python: Identifiera extremvärden med IQR-metoden.

```
import pandas as pd

# Läs in data
df = pd.read_csv("BilagaD_alkalinitet.csv", index_col=0)

# Identifiera extremvärden för varje kolumn i datatabellen
for col in df.columns:

    # Beräkna kvartiler
    Q1 = df[col].quantile(0.25)
    Q3 = df[col].quantile(0.75)

    IQR = Q3 - Q1   #Beräkna IQR

    # Beräkna lägre och övre gränser för extremvärden
    lower = Q1 - 1.5 * IQR
    upper = Q3 + 1.5 * IQR

    # Extrahera extremvärden från kolumnen med data
    outliers = df[col][(df[col] < lower) | (df[col] > upper)]
    print(col)
    print(outliers)
```

Z-score-metoden. Z-score beskriver hur många standardavvikelser en observation ligger från medelvärdet.

$$Z = \frac{x - \bar{x}}{s}$$

x är observationen, $\bar{x}$ är medelvärdet och *s* är standardavvikelsen.

Observationer med ett absolut Z-värde större än ungefär 3 betraktas ofta som potentiella extremvärden. Metoden fungerar bäst för data som är ungefär normalfördelade. För miljödata, som ofta är snedfördelade, är IQR-metoden vanligtvis mer robust.

Exempel i Python: Identifiera extremvärden med Z-score-metoden.

```
import pandas as pd
df = pd.read_csv("BilagaD_alkalinitet.csv", index_col=0)

# Identifiera extremvärden för varje kolumn i datatabellen
for col in df.columns:

    # Beräkna Z-värden
    z = (df[col] - df[col].mean()) / df[col].std()

    # Extrahera extremvärden från kolumnen med data
    outliers = df[col][abs(z) > 3]
    print(col)
    print(outliers)
```

När extremvärden har identifierats bör man ställa följande frågor:

- Är värdet rimligt med tanke på systemets funktion?
- Kan det bero på ett mätfel eller en felskrivning?
- Finns det någon dokumenterad händelse som kan förklara observationen?
- Hur påverkar extremvärdet medelvärdet, standardavvikelsen och andra analyser?

Först efter en sådan bedömning bör man avgöra om observationen ska behållas eller exkluderas från analysen. I många fall är extremvärden särskilt intressanta eftersom de kan avslöja ovanliga händelser eller problem i det system som undersöks. Genom att identifiera och utvärdera extremvärden får man en bättre förståelse för datakvaliteten och minskar risken för att dra felaktiga slutsatser från mätresultaten.

Presentation av data i en tabell

Låt oss anta att vi har mätt alkaliniteten i tre olika sjöar och vill sammanfatta resultaten i en tabell. Figur D-1 visar ett dåligt och ett bra exempel på en sådan tabell.

Den vänstra tabellen är problematisk av två skäl. För det första används ett olämpligt antal värdesiffror. Att rapportera fler siffror än vad mätningarnas precision motiverar kan ge ett falskt intryck av hög noggrannhet. För det andra saknas enheter, vilket gör det svårt att tolka resultaten. När mätresultat beräknas genom multiplikation eller division bör svaret normalt inte innehålla fler värdesiffror än det ingående mätvärde som har minst antal värdesiffror. Alkalinitet kan exempelvis beräknas enligt ekvationen nedan.

$$ALK_{TOT} = \frac{Volym_{syra} \cdot Konc_{syra}}{Volym_{vatten}}$$

Om volymen syra är 3,52 mL (3 värdesiffror), syrakoncentrationen är 0,1052 M (4 värdesiffror) och vattenvolymen är 50,0 mL (3 värdesiffror) bör den beräknade alkaliniteten anges med tre värdesiffror. När data presenteras måste enheter alltid anges. I tabeller är det ofta lämpligt att ange enheterna i kolumnrubriken. För mycket små eller stora tal kan tiopotensform användas för att göra tabellen mer lättläst.

Dålig

Sjö	Alkalinitet
Anksjön	0,95790
Grodsjön	0,00001972
Fisksjön	1,1507

Bra!

Sjö	Alkalinitet (mekv/L)
Anksjön	0,960
Grodsjön	$1{,}97 \cdot 10^{-5}$
Fisksjön	1,15

Figur D-1. Exempel på en bra och en dålig tabell.

Jämförelse av dataset i diagram

Antag att vi har gjort 20 alkalinitetsmätningar i vardera Anksjön och Fisksjön. Innan vi drar slutsatser om skillnader mellan sjöarna behöver vi undersöka både medelvärden eller medianvärden och variation. Figur D-2 visar tre olika sätt att presentera resultaten. Diagram X är mindre lämpligt eftersom endast medelvärden visas. Det går därför inte att bedöma hur stor variationen är inom respektive dataset eller om det finns extremvärden som påverkar resultaten. Diagram Y visar medelvärde och standardavvikelse, vilket ger information om både nivå och spridning. Diagram Z använder låddiagram (boxplots), vilka dessutom synliggör median, kvartiler och extremvärden. När mätserier jämförs bör man sträva efter att visa både centraltendens (medel eller median) och variation. Diagram som endast visar medelvärden riskerar att dölja viktig information.

En annan viktig aspekt är figurtexten och axeltexter. Det mittersta och det högra diagrammet (Y och Z) är bra. Vid y-axeln finns namnet på parametern och enheten. I figurtexterna finns information om vad som visas och antalet mätpunkter som diagrammen baseras på.

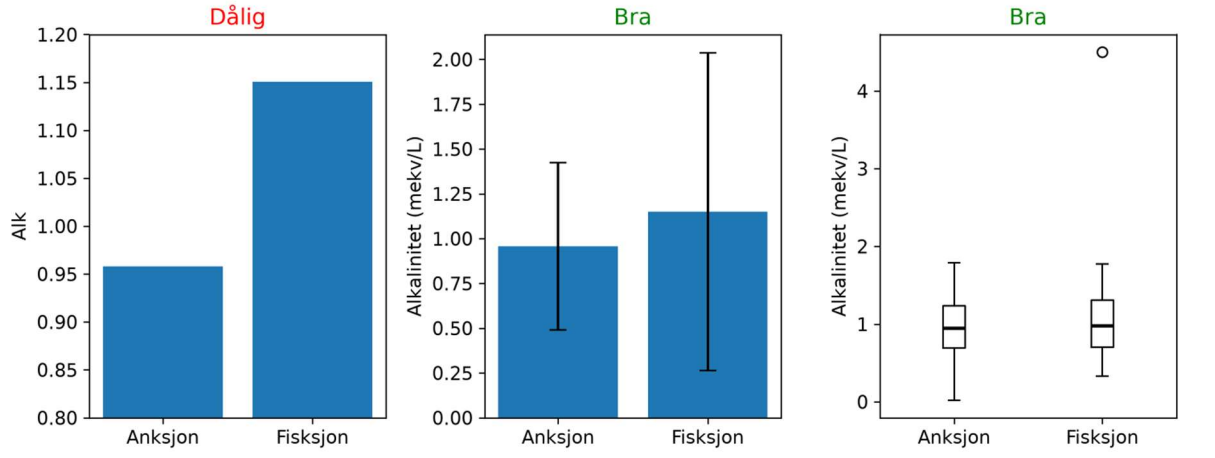


Diagram X. Alkalinitet.

Diagram Y. Alkalinitet (medelvärde±standardavvikelse, n=20).

Diagram Z. Alkalinitet presenterad som ett låddiagram (boxplot) baserat på 20 mätvärden. Diagrammet visar median, kvartiler, spridning och extremvärden.

Figur D-2. Exempel på ett dåligt och två bra diagram som jämför två dataset.

Exempel i Python: Gör ett låddiagram (boxplot).

```
import pandas as pd
import matplotlib.pyplot as plt

# Läs in data
df = pd.read_csv("BilagaD_alkalinitet.csv", index_col=0)

# Skapa figur
plt.rcParams.update({'font.size':11})
fig, ax = plt.subplots(1, 1, figsize=(4, 4))

# Box-plot
ax.boxplot(
    [df["Anksjon"],
     df["Fisksjon"]],
    tick_labels=["Anksjon", "Fisksjon"],
    widths=0.7,
    medianprops={"color":"black", "linewidth":2}
)
ax.set_ylabel("Alkalinitet (mekv/L)")
plt.tight_layout()
plt.show()
```

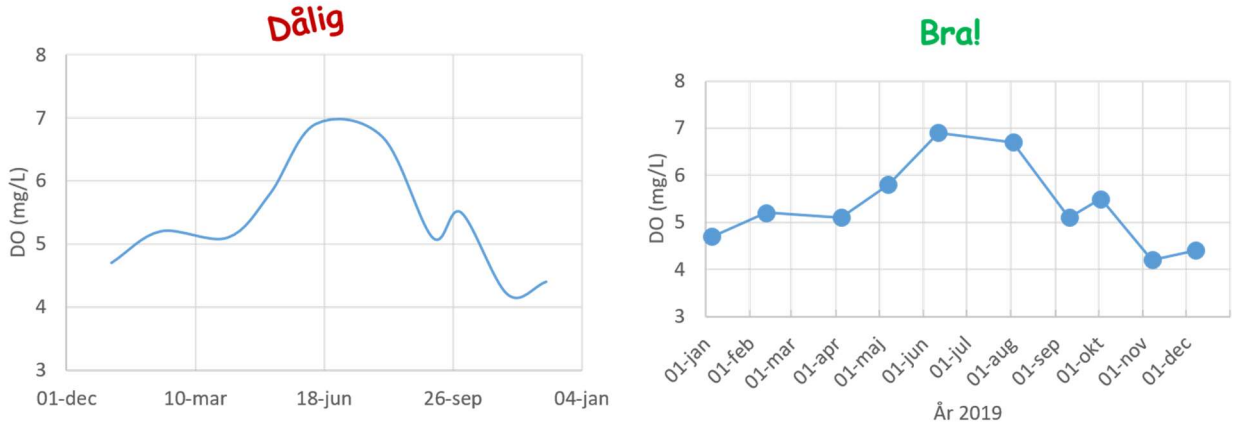
Visa trender över tid i diagram

I detta exempel antar vi att vi har mätt koncentrationen löst syre vid 10 tillfällen i en sjö under ett år. Vi vill illustrera i ett diagram hur syrekoncentrationen förändras under året. Figur D-3 visar ett bra och ett dåligt diagram. Det vänstra diagrammet är dåligt av följande anledningar:

- Det finns ingen information om när mätningar utfördes.
- Linjen är utjämnad (smoothed) mellan mätpunkterna trots att vi inte har någon information om hur syrekoncentrationen förändras där.
- Skalan på x-axeln är svår att följa.

Det högra diagrammet är bra. Varje mätvärde är tydligt markerat med en punkt. Linjen som binder samman punkterna är rak eftersom vi inte har någon information om hur syrekoncentrationen förändras där (det hade också varit okej att helt utelämna den linjen och bara visa punkterna). Diagrammets x-axel är tydligt indelad med en markering den 1:a varje månad och det finns information om vilket år som avses.

Tidsserier bör också granskas med avseende på avvikande observationer. Enstaka höga eller låga mätvärden kan ibland bero på mätfel men kan också representera verkliga händelser i systemet. Genom att visa varje mätpunkt blir det lättare att upptäcka sådana observationer.



Figur D-3. Exempel på ett bra och ett dåligt diagram som visar en serie av mätningar över tid. DO står för koncentrationen löst syre.

Exempel i Python: Plotta en tidsserie.

```
import pandas as pd
import matplotlib.pyplot as plt
import matplotlib.dates as mdates

# Läs data
df = pd.read_csv("BilagaD_DO.csv")

# Konvertera datum
df["Datum"] = pd.to_datetime(df["Datum"])

# Skapa figur
plt.figure(figsize=(6,4))

plt.plot(
    df["Datum"],
    df["DO"],
    marker="o",
    linewidth=2,
    markersize=8
)

plt.ylabel("DO (mg/L)")
plt.xlabel("År 2019")

# Markering den 1:a varje månad
plt.gca().xaxis.set_major_locator(mdates.MonthLocator())

# Format: 01-jan, 01-feb ...
plt.gca().xaxis.set_major_formatter(
    mdates.DateFormatter("%d-%b")
)

plt.xticks(rotation=45)
plt.ylim(0, 8)
plt.tight_layout()
plt.show()
```

Testa en hypotes: jämföra två medelvärden med t-test

Låt oss gå tillbaka till Figur D-2 där vi jämförde alkaliniteten i Anksjön och Fisksjön. Är det någon skillnad i alkalinitet mellan de två sjöarna? Om vi hade använt oss av diagram X så hade vi kanske dragit slutsatsen att alkaliniteten i Fisksjön är högst eftersom den är 1,15 mekv/L medan alkaliniteten i Anksjön bara är 0,96 mekv/L. Det är dock en felaktig slutsats. I diagram Y och Z ser vi att även om medelvärdet för alkaliniteten är högre i Fisksjön så är det en stor variation mellan individuella mätningar och alkaliniteten verkar vara ungefär lika hög i båda sjöarna.

Ibland vill man avgöra om skillnaden mellan två medelvärden beror på verkliga skillnader eller bara på slumpmässig variation i mätningarna. För detta kan man använda ett t-test. Anta att vi har mätt alkaliniteten 20 gånger i Anksjön och 20 gånger i Fisksjön. Medelvärdena för sjöarna är inte exakt lika stora, men frågan är om skillnaden är tillräckligt stor för att vi ska kunna säga att sjöarna faktiskt skiljer sig åt. T-testet utgår från en nollhypotes. I detta fall är nollhypotesen att den verkliga alkaliniteten är densamma i båda sjöarna. Testet beräknar sedan ett p-värde som anger hur sannolikt det är att få en skillnad minst så stor som den observerade om nollhypotesen är sann. Ett litet p-värde talar emot nollhypotesen. Ofta används gränsen 0,05. Om p-värdet är mindre än 0,05 betraktas skillnaden som statistiskt signifikant och vi förkastar nollhypotesen. Om p-värdet är större än 0,05 finns det inte tillräckligt starka bevis för att säga att sjöarna skiljer sig åt. Ett p-värde på 0,05 betyder att det finns ungefär 5 % sannolikhet att få en lika stor eller större skillnad mellan våra mätserier enbart av slumpen om sjöarna egentligen har samma alkalinitet. Punklistan nedan tydliggör de två nyckelbegrepp som presenteras i det här stycket:

- *Nollhypotes*: Ingen skillnad i medelvärden.
- *p-värde*: Ett mått på hur väl mätdata stämmer överens med nollhypotesen.
- $p < 0,05$: Skillnaden betraktas som statistiskt signifikant (men andra gränsvärden än 0,05 kan också användas).

Ett t-test för oberoende grupper förutsätter att observationerna är oberoende och att data i varje grupp är ungefär normalfördelade. Det klassiska Student's t-test förutsätter dessutom att grupperna har samma varians. Welch's t-test kräver inte att varianserna är lika och används därför ofta som standard. Om samma prov eller mätplatser har undersökts vid två tillfällen ska man i stället använda ett parat t-test. Om Vatten beskriver inte i detalj hur dessa olika statistiska test fungerar. Den informationen går dock hitta på många ställen, t.ex. Wikipedia och hemsidan Real Statistics (http://www.real-statistics.com). Excel och Pythonbiblioteken SciPy och Statsmodels, och många andra mjukvaror, innehåller funktioner som gör det enkelt att göra en mängd olika statistiska test.

I fallet med alkalinitet i Anksjön och Fisksjön utfördes analysen med Welch's t-test i Python, vilket beräknade ett p-värde på 0,40. Det betyder att vi inte kan förkasta nollhypotesen och resultatet gav inte tillräckligt stöd för att alkaliniteten skilde sig mellan sjöarna. Så här skulle resultatet kunna rapporteras: "Alkaliniteten i Anksjön var 0,96±0,47 mekv/L och i Fisksjön var den 1,15±0,89 mekv/L (medel±standardavvikelse). Det var ingen statistiskt signifikant skillnad i alkalinitet mellan de två sjöarna (p=0,40, t-test, n=20)."

Exempel i Python: t-test.

```
import pandas as pd
from scipy import stats

# Läs in data
df = pd.read_csv("BilagaD_alkalinitet.csv")

# Välj de två sjöar som ska jämföras
ank = df["Anksjon"]
fisk = df["Fisksjon"]

# Beräkna medelvärde och standardavvikelse
ank_mean = ank.mean()
ank_sd = ank.std(ddof=1)

fisk_mean = fisk.mean()
fisk_sd = fisk.std(ddof=1)

# Welch's t-test (rekommenderas i de flesta fall)*
t_stat, p_value = stats.ttest_ind(ank, fisk, equal_var=False)

# Skriv ut resultaten
print("Anksjön:", ank_mean, "±", ank_sd, "mekv/L")
print("Fisksjön:", fisk_mean, "±", fisk_sd, "mekv/L")
print("t-statistik=", t_stat)
print("p-värde=", p_value)

# Tolka resultatet
if p_value < 0.05:
    print("Skillnaden är statistiskt signifikant (p < 0,05).")
else:
    print("Ingen statistiskt signifikant skillnad (p ≥ 0,05).")
```

*Det klassiska t-testet förutsätter att de två grupperna har samma varians. Welch's t-test kräver inte detta antagande och fungerar därför bra även när spridningen skiljer sig mellan grupperna. Därför används Welch's t-test ofta som standard och specificeras i funktion genom *equal_var=False*.

Testa en hypotes: jämföra flera medelvärden med ANOVA

Vad gör vi om vi vill jämföra tre eller fler medelvärden? Anta att vi har mätt alkaliniteten i tre sjöar: Anksjön, Grodsjön och Fisksjön. Om vi jämför sjöarna två och två får vi tre parvisa jämförelser: Anksjön-Grodsjön, Anksjön-Fisksjön och Grodsjön-Fisksjön. Man skulle kunna göra ett t-test för varje jämförelse, men det är inte den bästa metoden. Ju fler statistiska test som genomförs, desto större blir risken att man av misstag hittar en skillnad som egentligen bara beror på slumpen.

När vi vill jämföra tre eller fler grupper börjar vi därför med en variansanalys (ANOVA, Analysis of Variance). Nollhypotesen är att alla grupper har samma medelvärde, det vill säga att alkaliniteten i de tre sjöarna är lika hög. ANOVA undersöker om variationen mellan gruppernas medelvärden är större än vad man kan förvänta sig från den naturliga variationen inom grupperna. Om ANOVA ger ett p-värde som är mindre än den valda signifikansnivån (ofta 0,05) kan vi förkasta nollhypotesen. Då vet vi att minst en av sjöarna skiljer sig från de andra, men inte vilken. För att ta reda på detta använder man ett så kallat post hoc-test som jämför grupperna parvis. Ett vanligt alternativ är Tukeys test, som identifierar vilka sjöar som skiljer sig åt samtidigt som risken för falska positiva resultat hålls på en rimlig nivå.

Exempel i Python: ANOVA följt av Tukey's HSD post-hoc test.

```
import pandas as pd
from scipy import stats
from statsmodels.stats.multicomp import pairwise_tukeyhsd

# Läs in data
df = pd.read_csv("BilagaD_alkalinitet.csv")

# Hämta data för de tre sjöarna
ank = df["Anksjon"]
grod = df["Grodsjon"]
fisk = df["Fisksjon"]

# ANOVA*
f_stat, p_value = stats.f_oneway(ank, grod, fisk)

print("ANOVA")
print("F=", f_stat)
print("p=", p_value)

if p_value < 0.05: #Om p-värdet är statistiskt signifikant utförs post-hoc test
    print("Minst en sjö skiljer sig från de andra.")

    # Tukey post-hoc
    # Omvandla dataframe till långt format
    long_df = pd.DataFrame({
        "Alkalinitet": pd.concat([ank, grod, fisk], ignore_index=True),
        "Sjo": (["Anksjon"] * len(ank) +
                ["Grodsjon"] * len(grod) +
                ["Fisksjon"] * len(fisk))
    })
    tukey = pairwise_tukeyhsd(
        endog=long_df["Alkalinitet"],
        groups=long_df["Sjo"],
        alpha=0.05
    )
    print("Tukey post-hoc test")
    print(tukey)

else: #Om p-värdet är inte är statistiskt signifikant utförs inte post-hoc
    print("Ingen statistiskt signifikant skillnad mellan sjöarnas medelvärden.")
```

*Klassisk envägs-ANOVA förutsätter att observationerna är oberoende, att residualerna är ungefär normalfördelade och att gruppernas varianser är ungefär lika. Om grupperna har tydligt olika varianser kan andra metoder behöva användas.

Undersöka ett samband med linjär regression

Låt oss anta att vi har 39 mätningar av koncentrationen av COD och totalkväve (TN) i avloppsvatten. Vi frågar oss om det finns ett linjärt samband mellan dessa två parametrar. I Figur D-4 visas mätvärdena i ett punktdiagram med COD-koncentration på x-axeln och TN-koncentration på y-axeln. Varje punkt representerar ett prov. Bara genom att studera punktdiagrammet kan vi misstänka att det finns ett positivt linjärt samband mellan COD och TN, eftersom högre COD-värden ofta verkar sammanfalla med högre TN-värden. För att undersöka detta mer systematiskt kan vi använda linjär regression. I Python kan en linjär regression utföras med paketet Statsmodels. Analysen anpassar en rät linje till mätpunkterna enligt ekvationen:

$$TN = a + b \cdot COD$$

där a är skärningen med y-axeln och b är linjens lutning.

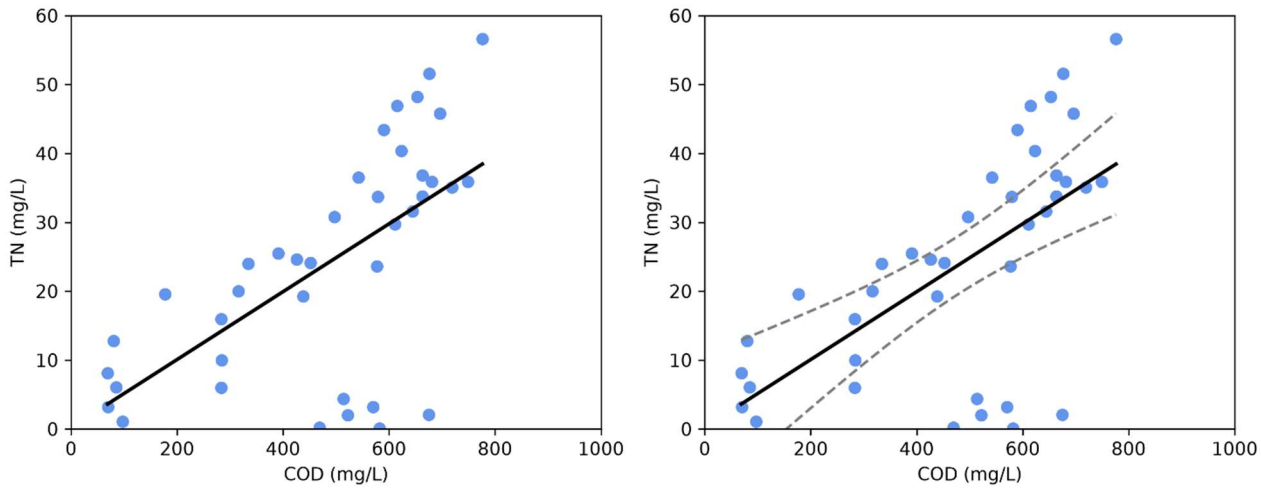
Regressionslinjen visas som den svarta linjen i Figur D-4. Om lutningen är positiv ökar TN i genomsnitt när COD ökar. Programmet beräknar också determinationskoefficienten (R^2), som beskriver hur stor del av variationen i TN som kan förklaras av variationer i COD. Ett R^2-värde nära 1 innebär att punkterna ligger nära regressionslinjen, medan ett värde nära 0 innebär att sambandet är svagt. Om exempelvis $R^2 = 0{,}40$ betyder det att 40% av variationen i TN kan förklaras av variationer i COD.

I det högra diagrammet visas dessutom ett 95-procentigt konfidensband runt regressionslinjen. Konfidensbandet beskriver osäkerheten i modellens skattning av det genomsnittliga TN-värdet vid olika COD-koncentrationer. Bandet är smalast där det finns mest information och blir vanligtvis bredare nära datamängdens ytterkanter.

För varje parameter i modellen beräknas även ett p-värde och ett 95%-konfidensintervall. Dessa mått kan användas för att testa hypoteser om sambandet mellan variablerna. Om vi vill undersöka om COD och TN är positivt korrelerade är nollhypotesen att lutningen *b* är lika med 0, vilket innebär att något linjärt samband inte finns. Om p-värdet för lutningen är mindre än 0,05 kan nollhypotesen förkastas och vi drar slutsatsen att det finns ett statistiskt signifikant samband mellan variablerna. Samma slutsats kan dras om värdet 0 inte ingår i lutningens 95%-konfidensintervall. Resultatet kan exempelvis rapporteras på följande sätt: ”Det fanns en statistiskt signifikant positiv korrelation mellan COD och TN (linjär regression, $p < 0{,}05$). Regressionsmodellen förklarade 40% av variationen i TN (R^2=0,40, n=39).”

Punklistan nedan sammanfattar de viktigaste begreppen:

- *Linjär regression:* Anpassar en rät linje till data.
- *Regressionslinje:* Den linje som bäst beskriver sambandet mellan variablerna.
- *R^2-värde:* Andelen av variationen i y-variabeln som kan förklaras av x-variabeln.
- *Lutning (b):* Hur mycket y förändras när x ökar med en enhet.
- *p-värde:* Ett mått på hur sannolikt det observerade sambandet är om den sanna lutningen egentligen är 0.
- *95 %-konfidensintervall:* Ett intervall av rimliga värden för modellparametrarna.



Figur D-4. Samband mellan koncentrationerna av COD och TN. De blå punkterna visar mätvärden och den svarta linjen visar den anpassade linjära regressionsmodellen. De grå streckade linjerna i det högra diagrammet visar ett 95-procentigt konfidensband för modellens skattning av genomsnittlig TN-koncentration.

Exempel i Python: Regressionsanalys med StatsModels.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import statsmodels.api as sm

# Läs in data
df = pd.read_csv("BilagaD_COD_TN.csv")

# Regression
X = sm.add_constant(df["COD"])
model = sm.OLS(df["TN"], X).fit()

# Fullständig sammanfattning
print(model.summary())

# Några nyckeltal
print("R2=", model.rsquared)
print("Lutning=", model.params['COD'])
print("p-värde=", model.pvalues['COD'])

# 95 % konfidensintervall
print("95 % konfidensintervall:")
print(model.conf_int())

# Prediktioner för linjen
x_pred = np.linspace(df["COD"].min(), df["COD"].max(), 100)
X_pred = sm.add_constant(x_pred)
pred = model.get_prediction(X_pred)
pred_df = pred.summary_frame(alpha=0.05)

# Skapa figur
fig, ax = plt.subplots(1, 2, figsize=(10, 4))

# Diagram 1: endast regressionslinje
ax[0].scatter(df["COD"], df["TN"], color="cornflowerblue")
ax[0].plot(x_pred, pred_df["mean"], color="black", lw=2)
ax[0].set_xlabel("COD (mg/L)")
ax[0].set_ylabel("TN (mg/L)")
ax[0].set_xlim(0, 1000)
ax[0].set_ylim(0, 60)

# Diagram 2: regressionslinje + 95% KI
ax[1].scatter(df["COD"], df["TN"], color="cornflowerblue")
ax[1].plot(x_pred, pred_df["mean"], color="black", lw=2)
ax[1].plot(x_pred, pred_df["mean_ci_lower"], color="gray", linestyle="--")
ax[1].plot(x_pred, pred_df["mean_ci_upper"], color="gray", linestyle="--")
ax[1].set_xlabel("COD (mg/L)")
ax[1].set_ylabel("TN (mg/L)")
ax[1].set_xlim(0, 1000)
ax[1].set_ylim(0, 60)
plt.tight_layout()
plt.show()
```